

Proyecto Final – Machine Learning para Regresiones

Para el dataset walmart.csv adjunto a este proyecto deberá desarrollar y encontrar un modelo de regresión que funcione lo mejor posible, tome en cuenta el siguiente flujo de trabajo para resolver el problema ya que cada punto tendrá una ponderación en la calificación final.

1. EDA – Exploratory Data Analysis: Luego de cargar el dataset proporcionado deberá realizar un análisis exploratorio de las variables disponibles en el dataset considerando los siguientes pasos:
 - a. Gráficas de Densidad – Deberá realizar una gráfica de densidad de cada variable continua del dataset (Weekly_Sales, Temperature, Fuel_Price, CPI, Unemployment) haciendo un comentario general sobre su opinión al respecto del resultado.
 - b. Para la variable Holiday_Flag y Store deberá realizar una gráfica de barras con la cantidad de ocurrencias de cada clase dentro de la columna. Posteriormente deberá realizar un boxplot entre esta variable y el target (Weekly_Sales) y mostrar un comentario sobre su opinión al respecto de los resultados.
 - c. Para la variable Date deberá mostrar una gráfica de serie temporal donde la serie sea el target (Weekly_Sales).
 - d. Posteriormente deberá mostrar una gráfica de la matriz de correlación entre todas las variables continuas.
 - e. Para finalizar el EDA deberá realizar un comentario sólido sobre sus hallazgos en el dataset previo a realizar un modelo, la idea es proporcionar una opinión a priori de lo que se puede esperar de las variables involucradas en este modelo.
2. Ingeniería de Características: Desarrolle los pasos de ingeniería de características que considere necesarios para producir una estructura válida para realizar predicciones, para esto deberá realizar el análisis pertinente para decidir qué procesos desarrollará y cómo los aplicará al dataset, posteriormente deberá construir un pipeline de sci-kit learn con los pasos finales que haya seleccionado, recuerde que para hacer ingeniería de características puede considerar las siguientes operaciones:
 - a. Imputación de variables numéricas y categóricas.
 - b. Codificación de variables categóricas.
 - c. Tratamiento de outliers.
 - d. Transformación de variables continuas.
 - e. Escalado de Variables.
3. Modelos de Regresión – Luego del EDA y considerando sus hallazgos, deberá desarrollar los siguientes pasos para implementar modelos de regresión:
 - a. Realice una partición de datos para entrenamiento y testing de los modelos resultantes (registro y calificación de los modelos).

- b. Con la variable Date cree nuevas columnas realizando una descomposición en año, mes y día, además agregue el día de la semana y si es fin de semana esto lo puede hacer usando la librería pandas. Al completar, elimine la columna de Date original.
- c. Verifique si su dataset tiene faltantes, en caso de ser así puede utilizar alguna estrategia de imputación como imputación por media o mediana.
- d. Defina un driver de control de entrenamiento y validación cruzada utilizando el método repeatedcv (Repeated Cross-Validation).
- e. Implemente los siguientes modelos considerando la métrica de RMSE como base para decidir que modelo funciona mejor, además considere utilizar optimización de hyper-parámetros, recuerde usar la variable Weekly_Sales como target y usar el bloque de entrenamiento para correr los experimentos de cross-validation, utilice al menos los siguientes modelos con optimización de hiper-parámetros:
 - i. Regresión Lineal múltiple,
 - ii. Support Vector Regression.
 - iii. Árboles de Decisión para regresiones.
 - iv. Random Forest para regresiones.
 - v. Gradient Boosting para regresiones.
 - vi. KNN para regresiones.
 - vii. Implemente al menos tres arquitecturas de redes neuronales para resolver el problema.
 - viii. Una vez ha realizado el entrenamiento de modelos, ordénelos del mejor al peor en función del RMSE y realice un comentario general sobre los resultados para cada tipo de modelo.
 - ix. Tome el dataset completo de Train (creado en el paso 1) y vuelva a entrenar con cada tipo de modelo con la configuración de hyper-parámetros ganadora si aplica.
 - x. Luego de tener cada modelo entrenado realice el registro del modelo para esto deberá, con el dataset de train completo, calcule el RMSE final de cada modelo con el dataset de testing (creado en el paso 1) guarde estos valores.
 - xi. Cree un dataframe con la información de cada modelo y sus resultados, su dataframe debe incluir las siguientes columnas:
 - 1. Id – numero de fila.
 - 2. Nombre del modelo.
 - 3. Hyper-parámetros ganadores.
 - 4. RMSE de registro – calculado con el dataset de testing luego de entrenar con todo el train.
 - 5. Listado de variables incluidas en el modelo.
 - 6. Tag del modelo – seleccionar el tag en función del rendimiento del modelo, recuerde que los modelos pueden ser Champions, Challengers o Deplicated.

7. Realice un comentario final sobre los resultados del experimento realizado.
8. Para finalizar, cree un archivo .csv con su tabla de resultados finales.

Deberá entregar un notebook con todo el código que desarrollo y el archivo .csv de salida.